

Fundamentele Matematice ale Algoritmilor Genetici

Asist. univ. dr. Mihai Tudor

Departamentul de Matematică, Universitatea din Craiova, România
Specializarea Matematică-Informatică

Aspecte introductive

Algoritmii genetici sunt o clasă de algoritmi de optimizare inspirați din procesele evolutive naturale. Din punct de vedere matematic, aceștia operează cu:

- ✓ **Spații de căutare** (search spaces);
- ✓ **Funcții de fitness** (objective functions);
- ✓ **Populații** - mulțimi finite de soluții candidate;
- ✓ **Operatori probabilistici** - folosiți pentru explorarea spațiului de căutare.

Reprezentarea Matematică a Populației

Definiția 1 (Cromozom/Individ): Un **cromozom** este o reprezentare codificată a unei soluții candidate, definit matematic ca $x \in \mathcal{X}$, unde \mathcal{X} este **spațiul de căutare**.

Definiția 2 (Populație): O **populație** la generația t este o mulțime finită $P(t) = \{x_1^{(t)}, x_2^{(t)}, \dots, x_n^{(t)}\}$, unde n este dimensiunea populației și $x_i^{(t)} \in \mathcal{X}$.

Reprezentări comune ale cromozomilor

- ✓ **Reprezentarea binară:** $\mathcal{X} = \{0, 1\}^l$, unde l este lungimea cromozomului;
 - ▶ Cromozom: $x = (x_1, x_2, \dots, x_l)$;
 - ▶ Cardinalitatea spațiului: $x_i \in \{0, 1\}$, $|\mathcal{X}| = 2^l$.
- ✓ **Reprezentarea reală:** $\mathcal{X} \subseteq \mathbb{R}^d$
 - ▶ Cromozom: $x = (x_1, x_2, \dots, x_d)$, $x_i \in [a_i, b_i] \subset \mathbb{R}$.

Funcția de Fitness și Concepte de Optimizare

Definiția 3 (Funcția de Fitness): **Funcția de fitness** (funcția obiectiv) este o aplicație $f : \mathcal{X} \rightarrow \mathbb{R}$ care asociază fiecărei soluții candidate o valoare numerică reprezentând "calitatea" acesteia.

Proprietăți Matematice ale funcției obiectiv

- ✓ Funcția obiectiv trebuie să fie **măsurabilă** pe spațiul \mathcal{X} pentru a permite compararea obiectivă a soluțiilor;
- ✓ Funcția obiectiv trebuie să fie **continuă** atunci când $\mathcal{X} \subseteq \mathbb{R}^d$;

$$\lim_{x \rightarrow x_0} f(x) = f(x_0), \quad \forall x_0 \in \mathcal{X}.$$

- ✓ În problemele complexe de optimizare se preferă folosirea **metodelor hibride** care combină algoritmi genetici cu metode de optimizare bazate pe **gradientul descendent**. În acest caz se impune ca funcția obiectiv să fie **diferențiabilă**;

Tipuri de Funcții Obiectiv

Funcțiile obiectiv sunt de două tipuri:

- ✓ **Funcții Unimodale** - au un unic punct de optim local;

Exemple:

- ▶ Funcția pătratică: $f(x) = -\sum_{i=1}^d a_i(x_i - b_i)^2, \quad a_i > 0;$
- ▶ Funcția sferică: $f(x) = -\sum_{i=1}^d x_i^2.$

- ✓ **Funcții Multimodale:** - au multiple puncte de optim local;

Exemple:

- ▶ Funcția Rastrigin: $f(x) = A \cdot d + \sum_{i=1}^d [x_i^2 - A \cos(2\pi x_i)];$
- ▶ Funcția Ackley: $f(x) = -20e^{-0.2\sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2}} - e^{\frac{1}{d} \sum_{i=1}^d \cos(2\pi x_i)} + 20 + e.$

Probleme de Optimizare

Fie $f : \mathcal{X} \rightarrow \mathbb{R}$ o funcție obiectiv. Definim:

- ✓ Minimul funcției: $\min_{x \in \mathcal{X}} f(x) = \inf\{f(x) : x \in \mathcal{X}\};$
- ✓ Maximul funcției: $\max_{x \in \mathcal{X}} f(x) = \sup\{f(x) : x \in \mathcal{X}\};$
- ✓ Argumentul minimului (argmin): $\arg \min_{x \in \mathcal{X}} f(x) = \{x \in \mathcal{X} : f(x) = \min_{y \in \mathcal{X}} f(y)\};$
- ✓ Argumentul maximului (argmax): $\arg \max_{x \in \mathcal{X}} f(x) = \{x \in \mathcal{X} : f(x) = \max_{y \in \mathcal{X}} f(y)\}.$

Pentru orice problemă de optimizare, avem:

$$f(\arg \min_{x \in \mathcal{X}} f(x)) = \min_{x \in \mathcal{X}} f(x)$$

;

$$f(\arg \max_{x \in \mathcal{X}} f(x)) = \max_{x \in \mathcal{X}} f(x)$$

.

Problema Generală de Optimizare în Algoritmi Genetici

Într-un context cât mai general, algoritmi genetici rezolvă problema:

$$x^* = \arg \max_{x \in \mathcal{X}} f(x)$$

unde:

- ✓ \mathcal{X} este spațiul tuturor cromozomilor posibili;
- ✓ $f(x)$ este funcția obiectiv;
- ✓ x^* este cromozomul optim căutat.

Algoritmul genetic nu va determina exact cromozomul optim. Va oferi o aproximare "cât mai bună" a acestuia.

$$x_{AG}^{(t)} \approx \arg \max_{x \in \mathcal{X}} f(x),$$

unde x_{AG} este "cel mai bun" cromozom din generația t .

Echivalența Problemelor de Optimizare

Teoremă (Echivalența Problemelor de Optimizare): *Orice problemă de minimizare poate fi transformată într-o problemă de maximizare echivalentă și invers, în sensul că setul soluțiilor optime rămâne neschimbat.*

Pașii demonstrației:

Fie $f : \mathcal{X} \rightarrow \mathbb{R}$ o funcție obiectiv și \mathcal{X} spațiu de căutare. Se cere să se determine cromozomul optim x^* astfel încât

$$x^* = \arg \min_{x \in \mathcal{X}} f(x).$$

Ne propunem să transformăm această problemă de **minimizare** într-o problemă de **maximizare**.

Fie $x^* \in \arg \min_{x \in \mathcal{X}} f(x)$. Prin definiție, obținem că:

$$f(x^*) \leq f(x), \quad \forall x \in \mathcal{X} \quad (1).$$

Înmulțim ambele părți ale inegalității (1) cu -1 :

$$-f(x^*) \geq -f(x), \quad \forall x \in \mathcal{X} \quad (2).$$

Substituind $g(x) = -f(x)$ în inegalitatea (2):

$$g(x^*) \geq g(x), \quad \forall x \in \mathcal{X} \quad (3).$$

Inegalitatea (3) înseamnă exact că x^* este un punct de maxim pentru funcția g , adică:

$$x^* = \arg \max_{x \in \mathcal{X}} g(x).$$

Echivalența Problemelor de Optimizare

Echivalența problemelor de optimizare are o serie de implicații pentru proiectarea algoritmilor genetici.

✓ Standardizarea Implementări

- ▶ Putem implementa doar algoritmi de maximizare;
- ▶ Orice problemă de minimizare se transformă prin $g(x) = f(x)$.

✓ Consistența Selecției;

- ▶ Întotdeauna selectăm indivizii cu fitness mai mare;
- ▶ Nu trebuie să schimbăm logica în funcție de tipul problemei.

✓ Simplificarea Operatorilor;

- ▶ Toți operatorii (selecție, crossover, mutație) funcționează identic;
- ▶ Nu sunt necesare implementări separate.

Operatori de Selecție (probabilistici)

Problema Fundamentală: Algoritmul Genetic (AG) aproximează soluția optimă

$$x^* = \arg \max_{x \in \mathcal{X}} f(x).$$

Întrebare: Cum decidem care cromozomi din generația actuală să folosim pentru a crea generația următoare?

Răspuns: Prin **selecție** — alegem cromozomii care vor fi părinți.

Exemplu Concret: Să presupunem că avem o populație inițială de 4 cromozomi la generația $t = 0$:

Cromozom	Reprezentare	Fitness
x_1	(1, 0, 1, 1, 0)	$f(x_1) = 12$
x_2	(0, 1, 1, 0, 1)	$f(x_2) = 8$
x_3	(1, 1, 0, 1, 1)	$f(x_3) = 18$
x_4	(0, 0, 1, 0, 0)	$f(x_4) = 3$

Întrebarea: Care cromozomi să alegem ca părinți pentru generația următoare?

Operatori de Selecție (probabilistici)

Strategii de Alegere

Strategie 1 – Aleatoriu (GREȘIT):

- ▶ Alegem aleatoriu: de exemplu x_2 și x_4 .
- ▶ **Problemă:** Ignorăm complet fitness-ul.

Strategie 2 – Doar cei mai buni (PARȚIAL GREȘIT):

- ▶ Alegem doar x_3 (fitness maxim).
- ▶ **Problemă:** Pierdem diversitatea.

Strategie 3 – Probabilistic bazat pe fitness (CORECT):

- ▶ Cromozomii cu fitness mare au șanse mai mari de selecție.
- ▶ Cei cu fitness mic păstrează totuși o șansă mică.

În contextul AG, *supraviețuirea* înseamnă a fi ales ca părinte pentru generația următoare.

- ▶ În natură: organismele mai adaptate au șanse mai mari să se reproducă.
- ▶ În AG: cromozomii cu fitness mai mare au șanse mai mari să fie aleși.

Implementarea Matematică - Simularea Procesului de Selecție

Pentru populația noastră:

$$f(x_3) = 18 > f(x_1) = 12 > f(x_2) = 8 > f(x_4) = 3.$$

Principiu: Probabilitatea de a fi ales ca părinte trebuie să respecte această ordine:

$$P(x_3) > P(x_1) > P(x_2) > P(x_4).$$

Întrebare: Cum transformăm fitness-ul în probabilități

Răspuns: Vom folosi ca metodă de bază: Normalizarea

Pasul 1: Calculăm suma totală a fitness-urilor.

$$S = 12 + 8 + 18 + 3 = 41.$$

Pasul 2: Calculăm probabilitatea de alegere a fiecărui cromozom. $P(x_i) = \frac{f(x_i)}{S}$.

Cromozom	Fitness	Calcul	Prob.	Procentaj
x_1	12	12/41	0.293	29.3%
x_2	8	8/41	0.195	19.5%
x_3	18	18/41	0.439	43.9%
x_4	3	3/41	0.073	7.3%

Implementarea Matematică - Simularea Procesului de Selecție

Întrebare: Cum alegem cromozomii care devin părinți pentru următoarea generație?

Pasul 1: Calculăm probabilitățile cumulate

Probabilitatea cumulată = suma tuturor probabilităților de la început până la cromozomul curent.

Pentru x_1 (primul cromozom):

- ▶ Probabilitatea cumulată = $0 + P(x_1) = 0 + 0.293 = 0.293$
- ▶ Intervalul de selecție pentru x_1 : $[0, 0.293)$

Pentru x_2 (al doilea cromozom):

- ▶ Probabilitatea cumulată = $P(x_1) + P(x_2) = 0.293 + 0.195 = 0.488$
- ▶ Intervalul de selecție pentru x_2 : $[0.293, 0.488)$

Pentru x_3 (al treilea cromozom):

- ▶ Probabilitatea cumulată = $P(x_1) + P(x_2) + P(x_3) = 0.293 + 0.195 + 0.439 = 0.927$
- ▶ Intervalul de selecție pentru x_3 : $[0.488, 0.927)$


Pentru x_4 (ultimul cromozom):

- ▶ Probabilitatea cumulată
= $P(x_1) + P(x_2) + P(x_3) + P(x_4) = 0.293 + 0.195 + 0.439 + 0.073 = 1.000$
- ▶ Intervalul de selecție pentru x_4 : $[0.927, 1.000]$

Implementarea Matematică - Simularea Procesului de Selectie

Întreaga informație dedusă până în prezent poate fi concentrată în următorul tabel:

Cromozom	Probabilitate	Probabilitate Cumulată	Interval de Selecție	Lungimea Intervalului
x_1	0.293	0.293	$[0, 0.293)$	0.293
x_2	0.195	0.488	$[0.293, 0.488)$	0.195
x_3	0.439	0.927	$[0.488, 0.927)$	0.439
x_4	0.073	1.000	$[0.927, 1.000]$	0.073



Implementarea Matematică - Simularea Procesului de Selecție

Pasul 2: Folosirea intervalelor de selecție determinate pentru a determina părinții viitoarei generații.

- ▶ Pentru fiecare cromozom generăm un număr random r din $[0, 1]$.
- ▶ Dacă numărul generat se găsește în **intervalul de selecție** al cromozomului x_i , atunci acesta devine părinte pentru următoarea generație.

Exemplu: Ne propunem să simulăm selecția părinților pentru următoarea generație, realizând 10 iterații.

Selecția	Număr aleatoriu	Cromozom ales	Motivul
1	0.15	x_1	$0.15 \in [0, 0.293)$
2	0.73	x_3	$0.73 \in [0.488, 0.927)$
3	0.45	x_2	$0.45 \in [0.293, 0.488)$
4	0.82	x_3	$0.82 \in [0.488, 0.927)$
5	0.06	x_1	$0.06 \in [0, 0.293)$
6	0.91	x_3	$0.91 \in [0.488, 0.927)$
7	0.35	x_2	$0.35 \in [0.293, 0.488)$
8	0.55	x_3	$0.55 \in [0.488, 0.927)$
9	0.95	x_4	$0.95 \in [0.927, 1.000]$
10	0.18	x_1	$0.18 \in [0, 0.293)$

Selecția Proporțională - Observații

Cele mai întâlnite **probleme** pe care le putem întâmpina în implementarea selecției proporționale - metodă folosită în exemplul anterior - sunt:

- ▶ **Fitness negativ** - în acest caz pot fi folosite metode de translație;
- ▶ **Fitness-uri egale** - selecția este uniformă, toți croozomii având șanse egale de a fi selectați;

Presiunea de selecție - cât de mult favorizăm cromozomii cu fitness mare

Presiunea prea Mare - Probleme

- ▶ **Avantaj:** Progres rapid către soluții bune;
- ▶ **Dezavantaj:** Risc să uităm zone bune neexplorate.

Presiunea prea Mică - Probleme

- ▶ **Avantaj:** Explorăm mult din spațiul de căutare;
- ▶ **Dezavantaj:** Progres foarte lent
- ▶ **Exemplu:** Dacă probabilitățile sunt aproape egale, alegem aproape aleatoriu.

Echilibrul Ideal

- ▶ Favorizăm cromozomii buni, dar nu îi eliminăm pe cei mai slabi;
- ▶ **Progres constant + păstrarea diversității.**

