

# Implementarea algoritmilor genetici

---

Asist.univ.dr Mihai Tudor

---

## Obiective

- Înțelegerea principiilor de bază ale algoritmilor genetici (AG).
- Implementarea unui algoritm genetic simplu în Python.
- Aplicarea lui pe exemple clasice (maximizare funcție, problema șirului țintă).

## 1 Componentele de bază:

- Populația: un set de soluții candidate (cromozomi).
- Funcția de fitness: evaluează calitatea fiecărei soluții
- Selecția: alege indivizii cei mai apti pentru reproducere.
- Încrucișarea (crossover): combină doi părinți pentru a genera descendenți.
- Mutația: modifică aleator o parte din descendenți pentru diversitate.
- Criteriul de oprire: atingerea unui număr maxim de generații sau a unei soluții suficient de bune.

## 2 Structura de bază a unui algoritm genetic:

1. Inițializează populația  $P$  cu soluții aleatoare;
2. Evaluează fitness-ul fiecărui individ din populația  $P$ ;
3. Cât timp nu s-a atins criteriul de oprire:
  - (a) Selectează părinți din populația  $P$ ;
  - (b) Aplică încrucișarea pentru a obține descendenți;
  - (c) Aplică mutația asupra descendenților;
  - (d) Evaluează fitness-ul descendenților;
  - (e) Creează noua populație  $P'$ ;
4. Returnează cea mai bună soluție găsită;

## 3 Aplicații

Vom implementa o serie de algoritmi genetici în Python.

### 3.1 Maximizarea numărului de biți activi (biți cu valoarea 1) într-un cromozom binar.

Vom implementa un algoritm genetic elementar având ca obiectiv optimizarea unui cromozom binar. Funcția de fitness este definită ca numărul total de biți de valoare 1 din cromozom. Problema de optimizare urmărește **maximizarea numărului de biți activați (1)** într-un individ. Un cromozom cu un număr mai mare de biți 1 este considerat superior din punct de vedere evolutiv. Pe parcursul generațiilor, algoritmul trebuie să conducă populația către indivizi cu fitness maxim.

#### Implementare

```
1 from random import*
2
3 # Functia de fitness (numarul de biti 1)
4 def fitness(cromozom):
5     return sum(cromozom)
6
7 # Generarea populatie de cromozomi binari
8 def init_populatie(n, dim):
9     #n - dimensiunea populatiei
10    #dim - numarul de biti din cromozom
11    populatie = []
12    for i in range(n):
13        cromozom = []
14        for j in range(dim):
15            bit = randint(0, 1)
16            cromozom.append(bit)
17        populatie.append(cromozom)
18    return populatie
19
20 # Implementarea selectiei (folosim selectia de tip turneu)
21 def selectie(populatie, fitness):
22     # alegem doi cromozomi aleator din populatie
23     a, b = sample(range(len(populatie)), 2)
24     # ajunge sa fie selectat cromozomul cu fitness-ul mai mare
25     if fitness[a] > fitness[b]:
26         return populatie[a]
27     else:
28         return populatie[b]
29
30 # Implementam one-point crossover
31 def incrucisare(p1, p2):
32     # generam random punctul de taiere
33     p = randint(1, len(p1) - 1)
34     # returnam descendentii prin combinare de segmente de la parinti
35     return p1[:p] + p2[p:], p2[:p] + p1[p:]
```

```

36
37 # Implementam mutatia simpla (flip bit)
38 def mutatie(cromozom, rata=0.01):
39     for i in range(len(cromozom)):
40         if random() < rata:
41             cromozom[i] = 1 - cromozom[i]
42
43 # Algoritmul genetic
44 def algoritm_genetic(dim_pop=10, dim_crom=8, generatii=20):
45     # pop - lista ce retine intreaga populatie de cromozomi
46     pop = init_populatie(dim_pop, dim_crom)
47
48     for g in range(generatii):
49     # fit - lista ce retine fitnesu=ul fiecarui cromozom
50         fit = []
51         for ind in pop:
52             fit.append(fitness(ind))
53         noua_pop = []
54         while len(noua_pop) < dim_pop:
55             p1 = selectie(pop, fit)
56             p2 = selectie(pop, fit)
57             c1, c2 = incrucisare(p1, p2)
58             mutatie(c1)
59             mutatie(c2)
60             noua_pop.append(c1)
61             noua_pop.append(c2)
62
63         for i in range(dim_pop):
64             pop.append(noua_pop[i])
65         print("Generatia",g+1, "cel mai bun = ",max(fit))
66
67     return max(pop, key=fitness)
68
69 # Rulare
70 rezultat = algoritm_genetic()
71 print("Cea mai buna solutie gasita:", rezultat)

```

### 3.2 Maximizarea unei funcții numerice

Fie funcția  $f : \mathbb{R} \rightarrow \mathbb{R}, f(x) = x^2$ . Creați un algoritm genetic care maximizează funcția pe intervalul  $[0, 31]$ . Reprezentarea cromozomilor se va face la nivel binar pe 5 biți.

#### Implementare

```

1
2 from random import*
3
4 # Functia de fitness (scorul fiecarui individ)
5 def fitness(cromozom):
6     # convertim cromozomul din sistem binar in sistem zecimal
7     x = 0
8     putere = 1

```

```

9  # parcurgem cromozomul de la dreapta la stanga
10     for bit in reversed(cromozom):
11         x=x+ bit * putere
12         putere=putere* 2
13 #returnam cromozomul in sistem zecimal
14     return x * x
15
16
17 # Generarea populatiei de cromozomi binari
18 def init_populatie(dim_pop, dim_cromozom):
19     populatie = []
20     for i in range(dim_pop):
21         cromozom = []
22         for j in range(dim_cromozom):
23             cromozom.append(randint(0, 1))
24         populatie.append(cromozom)
25     return populatie
26
27 # Implementarea selectiei (folosim selectia de tip turneu)
28 def selectie(populatie, fitness):
29     # alegem doi cromozomi aleator din populatie
30     a, b = sample(range(len(populatie)), 2)
31     # ajunge sa fie selectat cromozomul cu fitness-ul mai mare
32     if fitness[a] > fitness[b]:
33         return populatie[a]
34     else:
35         return populatie[b]
36
37 # Implementam one-point crossover
38 def incrucisare(p1, p2):
39     # generam random punctul de taiere
40     p = randint(1, len(p1) - 1)
41     # returnam descendentii prin combinare de segmente de la parinti
42     return p1[:p] + p2[p:], p2[:p] + p1[p:]
43
44
45 # Implementam mutatia simpla (flip bit)
46 def mutatie(cromozom, rata=0.01):
47     for i in range(len(cromozom)):
48         if random() < rata:
49             cromozom[i] = 1 - cromozom[i]
50
51 # Algoritmul genetic
52 def algoritm_genetic(dim_pop=6, dim_crom=5, generatii=10):
53     # pop - lista ce retine intreaga populatie initiala de cromozomi
54
55     #Generam populatia initiala de cromozomi
56     pop = init_populatie(dim_pop, dim_crom)
57
58     for g in range(generatii):
59     # fit - lista ce retine fitnesu=ul fiecarui cromozom

```

```

60     fit = []
61     for ind in pop:
62         fit.append(fitness(ind))
63     #noua_pop - lista ce retine noua populatie la fiecare generatie
64     noua_pop = []
65
66     while len(noua_pop) < dim_pop: #criteriul de oprire
67     #aplicam selectia parintilor
68         p1 = selectie(pop, fit)
69         p2 = selectie(pop, fit)
70     #generam descendentii pentru noua populatie folosind one - point
        crossover
        c1, c2 = incrucisare(p1, p2)
71     #aplicam mutatia asupra descendentilor pentru a crea diversitate
72         mutatie(c1)
73         mutatie(c2)
74         noua_pop.append(c1)
75         if len(noua_pop) < dim_pop:
76             noua_pop.append(c2)
77     #dupa incheierea unui ciclu complet (o generatie), actualizam
        populatia initiala cu populatia noua generata
78         pop = noua_pop
79         print(f"Generatia {g+1}: cel mai bun fitness = {max(fit)}")
80
81     #returnam cel mai bun cromozom dupa incheierea tuturor ciclurilor
        de evolutie
82         cel_mai_bun = pop[0]
83         cel_mai_bun_fitness = fitness(cel_mai_bun)
84         for cromozom in pop:
85             f = fitness(cromozom)
86             if f > cel_mai_bun_fitness:
87                 cel_mai_bun = cromozom
88                 cel_mai_bun_fitness = f
89
90         return cel_mai_bun, cel_mai_bun_fitness
91
92     #Rulare
93     rezultat, fit = algoritm_genetic()
94     x = int("".join(map(str, rezultat)), 2)
95     print("\nCea mai buna solutie gasita:")
96     print("Cromozom:", rezultat)
97     print("x =", x)
98     print("Fitness =", fit)

```